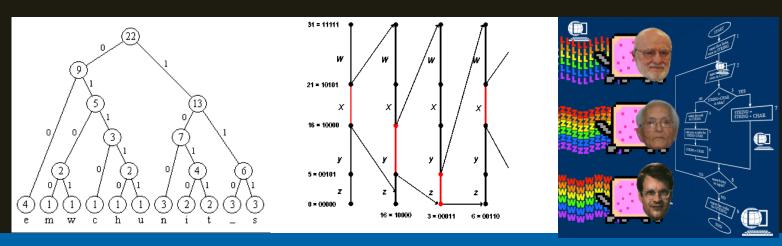


Multimedia: Kompression



Jonas Treumer / Ben Lorenz



Themen

- Datenkompression
 - (Verlustbehaftet) später
 - Verlustfrei
 - Entropiekodierer
 - Wörterbuchkodierer



Datenkompression

Ziele:



Datenkompression

- Ziele:
 - Datenreduktion → Speicherplatz, Übertragungsgeschwind.
- Mittel:



Datenkompression

- Ziele:
 - Datenreduktion → Speicherplatz, Übertragungsgeschwind.
- Mittel:
 - "Überflüssige" Informationen entfernen
 - Redundanzreduktion → verlustfrei
 - Irrelevanzreduktion → verlustbehaftet



Welche Daten können komprimiert werden?



Welche Daten können komprimiert werden?

- Verlustbehaftet: alle Daten
 - erkläre Teil der Daten als redundant/irrelevant
 - Originaldaten nicht eindeutig rekonstruierbar



Welche Daten können komprimiert werden?

- Verlustbehaftet: alle Daten
 - erkläre Teil der Daten als redundant/irrelevant
 - Originaldaten nicht eindeutig rekonstruierbar
- Verlustfrei: Daten, die Redundanz enthalten
 - Redundanz entfernen
 - Originaldaten exakt rekonstruierbar





 Völlig zufällige Daten lassen sich überhaupt nicht (verlustfrei) komprimieren



- Völlig zufällige Daten lassen sich überhaupt nicht (verlustfrei) komprimieren
- Taubenschlag/Schubfachprinzip
 - verteile n Objekte auf m Mengen $(M = \{M_1 ... M_m\})$ mit (m, n > 0) und $n > m \to \exists x \text{ mit } |M_x| \ge 2$



- Völlig zufällige Daten lassen sich überhaupt nicht (verlustfrei) komprimieren
- Taubenschlag/Schubfachprinzip
 - verteile n Objekte auf m Mengen $(M = \{M_1 ... M_m\})$ mit (m, n > 0) und $n > m \to \exists x \text{ mit } |M_x| \ge 2$
- Kolmogorov-Komplexität K
 - Länge der "kürzesten Bildungsvorschrift" für eine Zeichenkette s
 - $K(s) \ge length(s) \rightarrow s$ nicht komprimierbar



 Array aus Ganzzahlen mit großem Wertebereich? → größter Wert definiert Datentyp des Arrays



- Array aus Ganzzahlen mit großem Wertebereich? → größter Wert definiert Datentyp des Arrays
- großer Wertebereich, aber häufig kleine Zahlen = Verschwendung

1111 1101 0011 1110

0000 0000 0001 1111

0000 0000 0000 1011



- Array aus Ganzzahlen mit großem Wertebereich? → größter Wert definiert Datentyp des Arrays
- großer Wertebereich, aber häufig kleine Zahlen = Verschwendung

1111 1101 0011 1110 0000 0000 0001 1111 0000 0000 0000 1011

Verbesserung durch VarInt-Codierung:

 0
 1111 11111

 1
 001 1010
 0
 000 0101



- Array aus Ganzzahlen mit großem Wertebereich? → größter Wert definiert Datentyp des Arrays
- großer Wertebereich, aber häufig kleine Zahlen = Verschwendung

 1111 1101 0011 1110
 0000 0000 0001 1111
 0000 0000 0001 1011

Verbesserung durch VarInt-Codierung:

 0
 111 1111

 1
 001 1010
 0
 000 0101
 Negative Zahlen?



- Bsp.-Präkodierung für VarInts:
 - Deltakodierung
 - 260, 261, 256, 265, 262 → 260, 1, -4, 5, 2
 - Move-To-Front Transformation (siehe Tafel)
 - Zeichen werden durch ihre Position in einem Alphabet kodiert
 - Alphabet "rotiert", häufige Zeichen stehen weiter vorn



Entropiekodierer - Lauflängenkodierung (RLE)



Entropiekodierer - Lauflängenkodierung (RLE)

100011110100001111 1341144 AAAABBBBBBBBCCCCC {A,4}{B,8}{C,5}



Entropiekodierer - Lauflängenkodierung (RLE)

100011110100001111 1341144 AAAABBBBBBBBCCCCC {A,4}{B,8}{C,5}

- Burrows-Wheeler-Transformation (siehe Tafel)
 - Präkodierung, um zB Input für RLE zu verbessern



- David A. Huffman (1952)
- Quellsymbole → Codeworte variabler Länge



- David A. Huffman (1952)
- Quellsymbole → Codeworte variabler Länge
- Codeworte sind präfixfrei



- David A. Huffman (1952)
- Quellsymbole → Codeworte variabler Länge
- Codeworte sind präfixfrei
- Kodierer:
 - Input:
 - Nachricht
 - Auftrittswahrscheinlichkeit der Symbole
 - Output:
 - Codeworttabelle

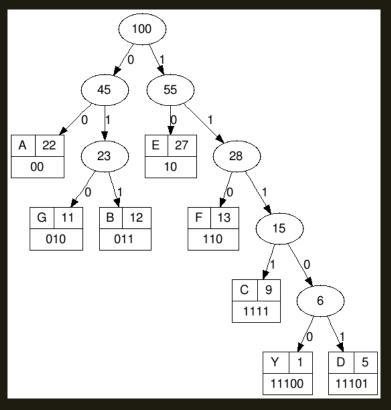


- David A. Huffman (1952)
- Quellsymbole → Codeworte variabler Länge
- Codeworte sind präfixfrei
- Kodierer:
 - Input:
 - Nachricht
 - Auftrittswahrscheinlichkeit der Symbole
 - Output:
 - Codeworttabelle
- Dekodierer:
 - Input:
 - Komprimierter Datenstrom
 - Codeworttabelle
 - Output:
 - Dekodierte Nachricht



- Gegeben sei folgendes Symbolalphabet und die Auftrittswahrscheinlichkeiten der Symbole:
- A:22%, B:12%, C:9%, D:5%, E:27%, F:13%, G:11%, Y:1%
- Stellen Sie mit Hilfe des Huffman-Algorithmus eine Codetabelle für dieses Symbolalphabet auf.
- Weisen Sie bei jeder Verzweigung des Baumes jeweils dem Knoten mit der kleineren kombinierten Häufigkeit die Ziffer 0 und dem Knoten mit der größeren kombinierten Häufigkeit die Ziffer 1 zu.
- Dekodieren Sie: 0110001100111000001000





Dekodieren Sie: 0110001100111000001000



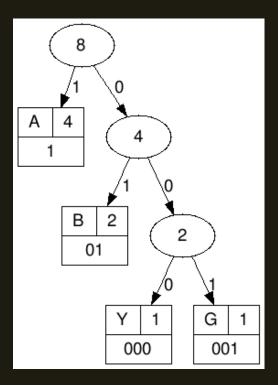
- BABAYAGA
- Erzeugen Sie aus diesem Wort mit Hilfe der Huffman-Kodierung die binären Codeworte für die einzelnen Symbole.
- Optimale Codewortlänge?

$$H \le \bar{l} \le H + 1$$

$$H = -\sum p_z \log_2 p_z$$



- BABAYAGA
- Erzeugen Sie aus diesem Wort mit Hilfe der Huffman-Kodierung die binären Codeworte für die einzelnen Symbole.

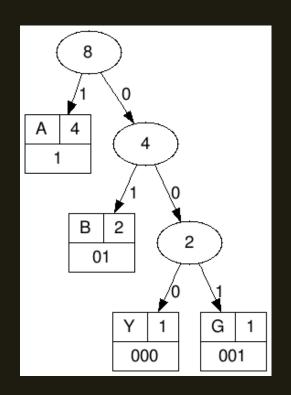




- BABAYAGA
- Erzeugen Sie aus diesem Wort mit Hilfe der Huffman-Kodierung die binären Codeworte für die einzelnen Symbole.
- Optimale Codewortlänge?

$$H \le \bar{l} \le H + 1$$

$$H = -\sum p_z \log_2 p_z$$





- BABAYAGA
- Erzeugen Sie aus diesem Wort mit Hilfe der Huffman-Kodierung die binären Codeworte für die einzelnen Symbole.
- Optimale Codewortlänge?

$$H \le \bar{l} \le H + 1$$

$$H = -\sum p_z \log_2 p_z$$



- BABAYAGA
- Erzeugen Sie aus diesem Wort mit Hilfe der Huffman-Kodierung die binären Codeworte für die einzelnen Symbole.
- Optimale Codewortlänge?

$$\bar{l}=2.25$$
 $H=1.75$ $1.75 \leq 2.25 \leq 2.75 \rightarrow Codewortlänge optimal$



- BABAYAGA
- Erzeugen Sie aus diesem Wort mit Hilfe der Huffman-Kodierung die binären Codeworte für die einzelnen Symbole.
- Optimale Codewortlänge?
- Codewortlänge?



- BABAYAGA
- Erzeugen Sie aus diesem Wort mit Hilfe der Huffman-Kodierung die binären Codeworte für die einzelnen Symbole.
- Optimale Codewortlänge?
- Codewortlänge?
 - 14 Bit



Entropiekodierer - Arithmetische Kodierung



Entropiekodierer - Arithmetische Kodierung

Nachricht wird als einzelne Zahl kodiert



Entropiekodierer - Arithmetische Kodierung

- Nachricht wird als einzelne Zahl kodiert
- Kodierer:
 - Input:
 - Nachricht
 - Auftrittswahrscheinlichkeit der Zeichen
 - Output:
 - Zahl



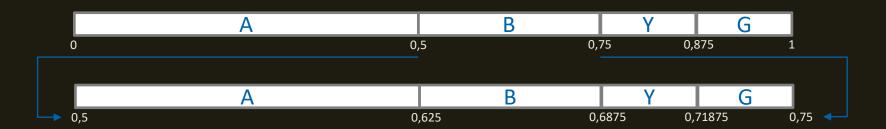
Entropiekodierer - Arithmetische Kodierung

- Nachricht wird als einzelne Zahl kodiert
- Kodierer:
 - Input:
 - Nachricht
 - Auftrittswahrscheinlichkeit der Zeichen
 - Output:
 - Zahl
- Dekodierer:
 - Input:
 - Zahl
 - Auftrittswahrscheinlichkeit der Zeichen
 - Anzahl Zeichen in Nachricht (?)
 - Output:
 - Nachricht

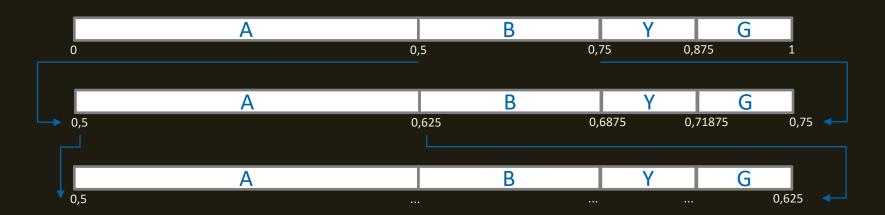




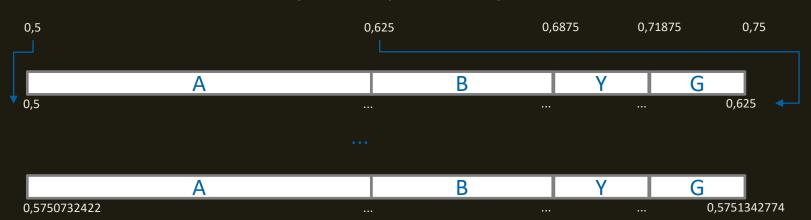




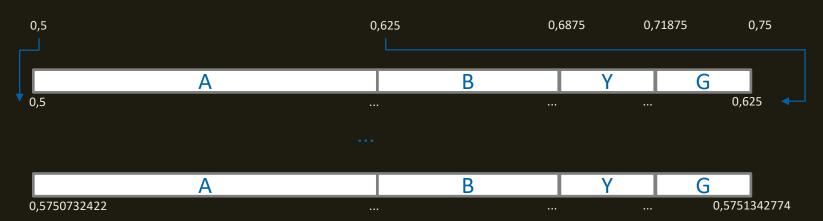






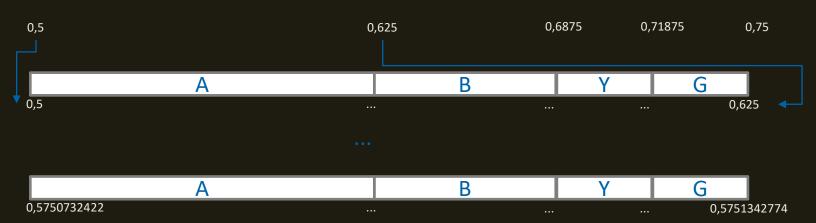






- Beliebige Zahl aus Intervall: 0,5751
- Wie viele Bits?





- Beliebige Zahl aus Intervall: 0,5751
- Wie viele Bits? 13 Bit (vs 14 Bit Huffman-Kodierung)

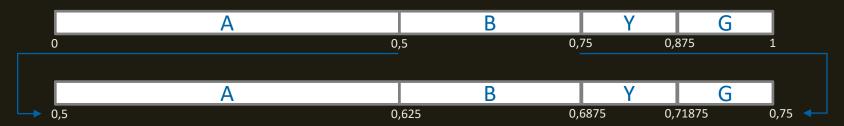


- BABAYAGA A: 50%, B: 25%, Y: 12.5%, G: 12.5%
- 0,5751 im Intervall [0,5;0,75] B Intervallgrenzen anpassen





- BABAYAGA A: 50%, B: 25%, Y: 12.5%, G: 12.5%
- 0,5751 im Intervall [0,5;0,75] B Intervallgrenzen anpassen



• 0,5751 im Intervall [0,5;0,625] – A – Intervallgrenzen anpassen ...



BABAYAGA A: 50%, B: 25%, Y: 12.5%, G: 12.5%



0,5751 im Intervall [0,5625;0,59375] – B – Intervallgrenzen anpassen...

TU Bergakademie Freiberg | Institut für Informatik| Professur für Betriebssysteme und Kommunikationstechnologien | Bernhard-von-Cotta-Straße 2 | Jonas Treumer / Ben Lorenz



Dynamische Wörterbuchkompression



- Dynamische Wörterbuchkompression
- GIF Format, TIFF und PDF optional



- Dynamische Wörterbuchkompression
- GIF Format, TIFF und PDF optional
- Kodierer und Dekodierer bauen Wörterbuch "on-the-fly" auf
- Maximale Codewortlänge 12 Bit = 4096 Einträge im Wörterbuch
- Erste 256 Einträge fest (0-255)



- Dynamische Wörterbuchkompression
- GIF Format, TIFF und PDF optional
- Kodierer und Dekodierer bauen Wörterbuch "on-the-fly" auf
- Maximale Codewortlänge 12 Bit = 4096 Einträge im Wörterbuch
- Erste 256 Einträge fest (0-255)



ABRAKADABRA



Lempel-Ziv-Welch-Kodierung

- ABRAKADABRA -> AB -> (256) -> A ausgeben
- BRAKADABRA -> BR -> (257) -> B ausgeben
- ...



Lempel-Ziv-Welch-Kodierung

- ABRAKADABRA -> AB -> (256) -> A ausgeben
- BRAKADABRA -> BR -> (257) -> B ausgeben
- RAKADABRA -> RA -> (258) -> R ausgeben
- AKADABRA -> AK -> (259) -> A ausgeben
- KADABRA -> KA -> (260) -> K ausgeben
- ADABRA -> AD -> (261) -> A ausgeben
- DABRA -> DA -> (262) -> D ausgeben
- ABRA -> AB -> (256) ausgeben
- RA -> (258) ausgeben
- ABRAKAD(256)(258)



Lempel-Ziv-Welch-Dekodierung

- P Präfix & C Cache
- ABRAKAD(256)(258)

```
P = ..A"
• A ->
• B -> \overline{C} = "B"; P&C = "AB" -> (256);
                                                P = ..B"
• R -> C = R''; P&C = BR'' -> (257);
                                                P = R
• A -> C = "A"; P&C = "RA" -> (258);
                                                P = ..A"
• K -> C = "K"; P&C = "AK" -> (279);
                                                P = ..K"
• A -> C = "A": P&C = "KA" -> (260):
                                                P = ..A"
• D -> C = D^*; P&C = AD^* -> (261):
                                                P = ..D"
• (256) -> C = "A"; P&C = "DA" -> (262);
                                                P = (256) = AB
• (258) -> C = "R"; P&C = "(256)R" -> (263);
                                                P = (258) = RA
```



Lempel-Ziv-Welch-Dekodierung

- ABRAKADABRA
 - 8Bit / Zeichen
 - 11 Zeichen * 8 Bit = 88 Bit
- ABRAKAD(256)(258)
 - 9 Bit / Wörterbucheintrag
 - 7 Zeichen * 9 Bit + 2 * 9 Bit = 81 Bit



Progammieraufgabe: Honkpack

1 Byte Indikator, n Bytes Datenblock

Indikator: Indikatorbyte

→ Bit 7: Typ des Blocks t |

1 → homogener Block0 → heterogener Block

 \rightarrow Bit 0-6: Dekomprimierte Länge der Blocks (l <= 127)

Datenblock:

- \rightarrow Homogen: Es folgt genau ein Byte (n=1), das l-mal wiederholts ausgegeben wird
- \rightarrow Heterogen: Es folgen l Bytes (n = l), die unverändert ausgegeben werden

1111111

6543210



Progammieraufgabe: Honkpack

Beispiel:

```
komprimiert (2 + 4 + 2 + 2 = 10 Bytes):
84 2A | 03 01 02 03 | FF 00 | 01 77
hom. het. hom. het.
1=4 | 1=3 | 1=127 | 1=1

dekomprimiert (4 + 3 + 127 + 1 = 135 Bytes):
2A 2A 2A 2A | 01 02 03 | 00 00 00 ... 00 | 77
```